

パッケージ環境の再現ツールと新しい相関指標

鈴木 了太

suzuki@ef-prime.com

株式会社 ef-prime

2025年12月6日

Japan.R 2025

自己紹介

鈴木 了太

- 株式会社 ef-prime 代表取締役
- データ分析ツールの開発・公開

株式会社 ef-prime

- 法人向けデータ分析関連サービス
- コンサルティング、ソフトウェア開発、研修
- 2006年設立


<https://ef-prime.com/>

R AnalyticFlow

データ分析のプロセスをワークフローで表現するR GUI

<https://r.analyticflow.com/>

- GUI操作とスクリプトの両方をサポートし、分析プロセスの共有を支援




pvclust

マルチスケールブートストラップ法による階層型クラスター分析の信頼性評価

<https://CRAN.R-project.org/package=pvclust>

- Suzuki & Shimodaira (2006) "Pvclust: an R package for assessing the uncertainty in hierarchical clustering", *Bioinformatics*



■ 本日のテーマ

パッケージ環境の再現ツールと新しい相関指標

パッケージ環境の再現ツール

Rスクリプトの動作環境を再現

新しい相関指標

離散データや非線形関係にも対応

R研究集会2025（2025/11/23 統計数理研究所）と同様のテーマですが、今回は実務に効くポイントにフォーカスしてお話しします。

パッケージ環境の再現ツール

よくある問題

- かつて書いたRスクリプトを動かしたい
- 現行の環境ではエラーで停止
- 当時のバージョンのRをインストールしても問題が生じる
 - CRANから取得するパッケージは現行版のため、エラーで停止
 - 当時のバージョンのパッケージを取得しても、依存関係の解決を `install.packages()` 関数に任せると現行版を取得してしまい、互換性がなくエラーで停止

依存関係も含めて、当時のパッケージ環境を再現する必要がある

理想と現実

理想

開発時から再現可能な環境を整備。例えば：

- コンテナ環境を構築し、OS、R、パッケージを一括で保管
- `renv`パッケージでプロジェクトごとにパッケージを管理
- `miniCRAN`パッケージでポータブルなローカルレポジトリを作成

現実

Rスクリプトの再現可能性は必ずしも十分ではない

- 実行環境の再現ツールは比較的最近になって発展
- 「間に合わせ」で書いたスクリプトが生き残ることも

かつての解決策

CRAN (MRAN) Time Machine

- Microsoft社が提供していたCRANスナップショット機能
 - バイナリ、ソースコードいずれも対応
- 日付を含むURLを指定すると、その時点のバージョンをインストール可能
 - 2014/9/17以降をサポート
<https://www.r-bloggers.com/2019/05/mran-snapshots-and-you-2/>
 - 2023/7/1にサービス停止
<https://www.r-bloggers.com/2023/01/mran-time-machine-will-be-retired-on-july-1/>

例：2023/3/1時点のrangerパッケージをインストール（現在は動作しない）

```
install.packages("ranger",  
  repos = "https://cran.microsoft.com/snapshot/2023-03-01/")
```

現在のおすすめ

Posit Package Manager (PPM)

<https://packagemanager.posit.co>

- CRAN Time Machineと同様にスナップショットが利用可能
 - バイナリ、ソースコードに対応（ただし一部バイナリは対象外）
 - 2017/10/10以降をサポート
<https://posit.co/blog/migrating-from-mran-to-posit-package-manager/>
 - Posit社がソースからバイナリを独自ビルド
<https://posit.co/blog/the-road-to-building-ten-million-binaries/>

例：2023/3/1時点のrangerパッケージをインストール

```
install.packages("ranger",  
  repos = "https://packagemanager.posit.co/cran/2023-03-01")
```

もうひとつの選択肢

datebackパッケージ

<https://github.com/r-suzuki/dateback>

仮想CRANスナップショットのように動作

- CRANから特定の日付のパッケージを依存関係も含めて取得
- 外部サービスに依存せず、R上で動作するオープンソースソフトウェア
- **ソースコードのみ**対応、原理上は日付の制限なし（詳細は後述）

例：2023/3/1時点のrangerパッケージをインストール

```
dateback::install("ranger", date = "2023-03-01",  
  repos = "https://cloud.r-project.org")
```

使用例

準備

datebackパッケージをCRANからインストール

```
install.packages("dateback")
```

パッケージのインストール

例：2024/9/1時点のrangerパッケージを依存関係も含めてインストール

```
dateback::install(pkgs = "ranger", date = "2024-09-01")
```

library(dateback)の後にinstall()でも動作するが、基本的にはdateback::install()の形式を推奨

使用例

ローカルレポジトリの作成

ディレクトリ `local_repo` を指定してパッケージを収集：

```
dateback::collect(pkgs = "ranger", date = "2024-09-01",  
                  outdir = "local_repo")
```

指定したディレクトリに **ローカルレポジトリ** が構築される：

```
local_repo/src/contrib/  
  PACKAGES  PACKAGES.gz  ranger_0.16.0.tar.gz  
  Rcpp_1.0.13.tar.gz      RcppEigen_0.3.4.0.2.tar.gz
```

ローカルレポジトリからのインストール。別マシンにコピーしても動作：

```
install.packages(pkgs = "ranger", repos = "file:local_repo")
```

使用例

取得パッケージの一覧

2025/11/18時点での実行ログ（抜粋）：

	package	file	date	status
1	Rcpp	Rcpp_1.0.13.tar.gz	2024-07-17	archive
2	RcppEigen	RcppEigen_0.3.4.0.2.tar.gz	2024-08-24	latest
3	ranger	ranger_0.16.0.tar.gz	2023-11-12	archive

- `ranger`は`Rcpp`および`RcppEigen`に依存
- `RcppEigen`のみ最新版、他のふたつはアーカイブから旧版を取得

使用例

より複雑な例

依存関係が多い、または複雑な場合に特に有用。以下は
`rstan`パッケージについて、2024/9/1時点のファイルを取得した例：

	package	file	date	status
1	RcppParallel	RcppParallel_5.1.9.tar.gz	2024-08-19	archive
2	Rcpp	Rcpp_1.0.13.tar.gz	2024-07-17	archive
3	RcppEigen	RcppEigen_0.3.4.0.2.tar.gz	2024-08-24	latest
...				
45	ggplot2	ggplot2_3.5.1.tar.gz	2024-04-23	archive
46	BH	BH_1.84.0-0.tar.gz	2024-01-10	archive
47	rstan	rstan_2.32.6.tar.gz	2024-03-05	archive

当時の`rstan`は14パッケージに依存（`base/recommended`を除く）。
再帰的な依存関係も含めると、計**47パッケージ**を取得する必要があった

動作の概要

CRANにアクセスし、以下に相当する処理を実施：

1. パッケージを検索。見つからなければ[/src/contrib/Archive/](#)も参照
2. パッケージの最新リリース日を確認（例：[2024-11-08](#)）
3. リリース日が指定日（例：[2024-09-01](#)）以前であれば最新版を取得。
そうでなければ指定日以前の最新のアーカイブを取得
4. 取得した[tar.gz](#)ソースを展開し、依存パッケージを確認。
これらについても再帰的に上記の手順を適用

依存パッケージについて、既にダウンロード済みのパッケージは再処理を行わない。
そのほか既定の挙動は以下の通り（オプションで変更可能）：

- [install\(\)](#)では実行時にインストール済みのパッケージはスキップ
- [collect\(\)](#)ではインストール済みのパッケージも取得するが、[recommended](#)パッケージはスキップ

仕様の詳細

動作要件

- 現時点ではR $\geq$ 3.2.0 (2015/4/16) が必要
 - 少なくとも10年前までは比較的容易に対応可能
 - R $\geq$ 3.2.0において`collect()`でローカルレポジトリを作成し、R $<$ 3.2.0から利用することも可能
- CRANの仕様に依存。特に過去バージョンの取得はWebスクレイピングを用いているため、将来的にサイト構造が変わると改修が必要
- なるべく多くの環境で動作させるため、外部パッケージに依存しない設計

開発当初はWebスクレイピングのために`curl`, `desc`, `httr`, `rvest`などのパッケージを利用していたが、上記方針のためbase-Rで書き直した。同様に`dplyr`や`%>%`パイプも不使用

仕様の詳細

対象パッケージ

原理上はCRAN上にあるすべてのパッケージおよびバージョンが対象。
現時点では以下に注意：

- R-1.9.0（2004/4/12）でパッケージの再編があり、統合前のパッケージがDESCRIPTIONファイルに含まれる場合、アーカイブからの取得に失敗する場合がある
 - 例：2003/8/1時点のHmiscはmvaに依存しており、これが原因で失敗
 - R-1.9.0ではctest, eda, lqs, modreg, mva, nls, stepfun, tsがstatsに統合（<https://developer.r-project.org/190update.txt>）

■ 活用例

Windows/Macおよびコンテナ以外のLinux環境

- 2017/10/10以降の日付
 - Posit Package Managerを利用（ただし一部バイナリは要ビルド）
- それより前の日付（**パッケージをビルドできる環境が必要**）
 - `R >= 3.2.0`で`dateback::install()`
 - `R >= 3.2.0`で`dateback::collect()`によって
ローカルレポジトリを構築し、`R < 3.2.0`にコピーして利用

Linuxコンテナ環境の構築

`dateback::install()`でコンテナからインストール、または
`dateback::collect()`でローカルレポジトリをあらかじめ用意

補足

- Windows上のRで`collect()`したローカルレポジトリのファイルを、Docker DesktopのLinuxコンテナからマウントして利用することも可能
- 2017/10/10以降の日付が対象であれば、PPM + `miniCRAN`の組み合わせでも特定の日付におけるローカルレポジトリを構築可能

パッケージ環境の再現ツール：まとめ

- 再現可能研究やスクリプトの開発・保守において、R実行環境の保存と復元が重要
- 研究・開発の初期段階から、コンテナ環境や`renv`、`miniCRAN`などを利用すると効果的
- 特定の日付におけるパッケージ環境を再現する方法として、`Posit Package Manager` (PPM) や`dateback`パッケージが利用可能
 - 2017/10/10以降の日付はPPM、それより前は`dateback`
 - `dateback`によるローカルレポジトリはコンテナ環境構築に便利

新しい相関指標

多変量データの相関分析

数値データ

- 古典的な手法は線形（または単調）関係を評価
 - 積率相関係数、順位相関係数
- 近年は非線形な関係に対応した手法も
 - 距離相関（distance correlation; Székely et al., 2007）
 - MIC（maximal information coefficient; Reshef et al., 2011）

カテゴリデータ

- 連関係数による独立性の評価
 - 例：クラメールの V 、ピアソンの ϕ 係数など

実務上の要求

データ型や分布を問わず適用したい

- 連続、離散、あるいはその混合
- 外れ値や欠損を含む
- 分布が非対称、裾が重い、多峰的

望ましい性質いろいろ

- 線形だけでなく非線形な関係も評価
- 測定単位を問わない（変換に対して不変）
- データや分析手法の前提知識が不要
- 計算コストが低く、大規模データにも適用可能

相関係数を一般化する

完全従属

- Y が X に**完全従属**する (complete dependence; Lancaster, 1963)
 - X による Y の条件付き分布が一点分布になること
 - $P(Y = g(X)) = 1$ となる可測関数 g が存在

一般化相関尺度



以下を満たす指標 $\text{gCor}(X, Y)$ を**一般化相関尺度**
(**generalized correlation measures**) と呼ぶことにする：

- $0 \leq \text{gCor}(X, Y) \leq 1$
- X と Y が独立のとき0、互いに完全従属するとき1
- (X, Y) が2変量正規分布に従うとき、相関係数の絶対値 $|\rho|$ と一致

新しい相関指標の提案


分割相関 (contingency correlation)

- χ^2 ダイバージェンスに基づく一般化相関尺度の推定値
- 連続変数を k 分位点で分割し、離散変数に変換して近似的に推定
- 数値とカテゴリを統一的に評価
- 名称はK. Pearson (1904)のfirst coefficient of contingencyに由来



離散化アプローチの利点

- 変数間の関係を2元分割表によって評価
- 行および列の順序を入れ替えても評価は変わらない
⇒ 非線形な関係を捉えることができる



分割数の自動選択

現行案：10対2ルール

$$k = \max \left\{ 2, \left\lfloor \frac{1}{2} n^{\log_{10} 2} \right\rfloor \right\}$$

- $n \leq 100$ のとき2分割、 n が10倍のとき k は2倍
- 数値シミュレーションで良好な結果
- 近似モデルに基づく理論上の検討とも整合
 - $k = o(n^{1/2})$ のとき $n \rightarrow \infty$ のもとで一致性が得られる

⇒ 分割数がサンプルサイズより緩やかに増えるため、スケーラブル

数値例

ランダム生成した2次元の数値データを評価
サンプルサイズ n 、分割数 k を動かして挙動を確認
標本相関係数と比較


Wikipedia「[ピアソンの積率相関係数](#)」掲載の例をもとに作成

- 出典：https://commons.wikimedia.org/wiki/File:Correlation_examples2.svg
 - CC0 1.0 Universal (パブリックドメイン)

$n = 1,000$ 標本相関係数

上段は相関係数 ρ の絶対値を1, 0.8, 0.4, 0に設定した2変量正規分布


小数点以下は1桁に丸めて表示（以降も同様）



$n = 1,000$ 分割相関 ($k = 4$)

10対2ルールに基づいて k を設定 ($n/k^2 = 62.5$)


非線形なパターンを検出しつつ、正規分布に対しては $|\rho|$ に近い値



$n = 100$ 標本相関係数

サンプルサイズが小さい場合


正規乱数に対しても多少の推定誤差が生じる



$n = 100$ 分割相関 ($k = 2$)

10対2ルールに基づいて k を設定 ($n/k^2 = 25$)


正規分布に対しては $|\rho|$ に近いが、非線形パターンを検出できていない



n = 100 分割相関 (k = 3)


セルごとの平均サンプルサイズが少なくなる ($n/k^2 \approx 11$)

近似バイアスが増加するものの、非線形パターンの検出には成功



$n = 10,000$ 標本相関係数


サンプルサイズが大きい場合について、小数点以下第2位まで表示
サンプルサイズを増やしても、非線形パターンについては0に近い



$n = 10,000$ 分割相関 ($k = 8$)

10対2ルールに基づいて k を設定 ($n/k^2 \approx 156$)


非線形パターンの検出は良好、近似バイアスも抑えられている



$n = 10,000$ 分割相関 ($k = 10$)

10対2ルールを参考に、集計結果が解釈しやすい k を設定 ($n/k^2 = 100$)

近似バイアスが若干増加するが、全体の傾向は大きく変わらない



ソフトウェア実装

Rパッケージ **gcor**

開発版をGitHubにて公開中（オープンソース）

<https://github.com/r-suzuki/gcor-r>

- 分割相関および関連指標を算出
- 数値とカテゴリの両方に対応
- 欠損値や外れ値を含むデータにも有効



変更履歴：パッケージURLを更新（2026/1/9）

サンプルデータ

irisデータ

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa

情報をもつ欠損 (informative missingness)

`Species == "setosa"` のとき50%の確率で `Sepal.Width` が欠損

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	NA	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	NA	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	NA	1.7	0.4	setosa

標本相関係数

カテゴリ値を含むためエラー

```
cor(iris)
```

```
Error in cor(iris): 'x' must be numeric
```

数値変数のみに限定して実行

```
cor(iris[, 1:4])
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.0000000	-0.1175698	0.8717538	0.8179411
Sepal.Width	-0.1175698	1.0000000	-0.4284401	-0.3661259
Petal.Length	0.8717538	-0.4284401	1.0000000	0.9628654
Petal.Width	0.8179411	-0.3661259	0.9628654	1.0000000

分割相関

数値とカテゴリを統一的に評価

```
gcor(iris)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Sepal.Length	1.0000000	0.2349075	0.8846517	0.8741873	0.7623968
Sepal.Width	0.2349075	1.0000000	0.3143301	0.2669031	0.6510740
Petal.Length	0.8846517	0.3143301	1.0000000	0.9503289	0.8221674
Petal.Width	0.8741873	0.2669031	0.9503289	1.0000000	0.8237429
Species	0.7623968	0.6510740	0.8221674	0.8237429	1.0000000

分割数 k を指定（既定ではサンプルサイズから自動設定）

```
gcor(iris, k = 3)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Sepal.Length	1.0000000	0.6180293	0.8449216	0.8300394	0.8226041
Sepal.Width	0.6180293	1.0000000	0.6862189	0.6963419	0.6794982
Petal.Length	0.8449216	0.6862189	1.0000000	0.9581278	0.9728947
Petal.Width	0.8300394	0.6963419	0.9581278	1.0000000	0.9795837
Species	0.8226041	0.6794982	0.9728947	0.9795837	1.0000000

標本相関係数（欠損を含むデータ）

欠損を含む列は算出されない

```
cor(iris_NA[, 1:4])
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.0000000	NA	0.8717538	0.8179411
Sepal.Width	NA	1	NA	NA
Petal.Length	0.8717538	NA	1.0000000	0.9628654
Petal.Width	0.8179411	NA	0.9628654	1.0000000

列の組ごとに、欠損を含むケースを無視する

```
cor(iris_NA[, 1:4], use = "pairwise.complete.obs")
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.00000000000	0.0002584192	0.8717538	0.8179411
Sepal.Width	0.0002584192	1.00000000000	-0.3163403	-0.2364441
Petal.Length	0.8717537759	-0.3163403009	1.0000000	0.9628654
Petal.Width	0.8179411263	-0.2364441194	0.9628654	1.0000000

分割相関（欠損を含むデータ）

「欠損という事象を観測した」ものとして評価

```
gcor(iris_NA)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Sepal.Length	1.0000000	0.5017295	0.8846517	0.8741873	0.7623968
Sepal.Width	0.5017295	1.0000000	0.5347735	0.5141064	0.7313361
Petal.Length	0.8846517	0.5347735	1.0000000	0.9503289	0.8221674
Petal.Width	0.8741873	0.5141064	0.9503289	1.0000000	0.8237429
Species	0.7623968	0.7313361	0.8221674	0.8237429	1.0000000

欠損を無視することも可能（この例では評価が変わる）

```
gcor(iris_NA, dropNA = "pairwise")
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Sepal.Length	1.000000000	0.009496501	0.88465174	0.87418733	0.7623968
Sepal.Width	0.009496501	1.000000000	0.09600307	0.04385796	0.5701664
Petal.Length	0.884651737	0.096003072	1.00000000	0.95032889	0.8221674
Petal.Width	0.874187331	0.043857963	0.95032889	1.00000000	0.8237429
Species	0.762396795	0.570166409	0.82216737	0.82374290	1.0000000

既存手法との比較

積率相関係数

- (X, Y) が2変量正規分布に従うとき、
分割相関は積率相関係数の絶対値に近い値をとる

距離相関 (distance correlation)

- 距離相関は「 X 軸において近ければ、 Y 軸でも近い」ことを測る
- 分割相関は独立性からの乖離を測り、距離の定義を必要としない


MIC (maximal information coefficient)

- MICは（基準化済み）相互情報量の観点から、最適な分割を探索する
- 分割相関は χ^2 相互情報量の推定に分割を用い、探索を必要としない

n = 1,000 標本相関係数


`cor(x,y)`で算出 (R標準の`stats::cor`)

数値例はいずれも前出のものと同じで、小数点以下は1桁に丸めて表示
以降、分割相関と絶対値の差が大きいものを強調表示



n = 1,000 分割相関

`gcor::gcor(x,y)` で算出。10対2ルールに基づいて $k = 4$ を自動設定
非線形なパターンを検出しつつ、正規分布に対しては $|\rho|$ に近い値
独立な場合でも0.1前後の値をとる（バイアス補正による改善を検討中）




n = 1,000 距離相関

`energy::dcor(x,y)`で算出。独立なケースを正しく評価できている

原論文 (Székely et al., 2007) でも検定における性能の良さが示されている

強い従属性があっても、条件付き分布に多峰性がある状況では低値をとる




n = 1,000 MIC

`minerva::mine(x,y)$MIC`で算出。正規分布では ρ^2 に近い値

原論文 (Reshef et al., 2011) でも「 R^2 に近い値」をとる傾向が記されている


独立なケースでの値は分割相関と類似の傾向 (0.1前後) を示す



n = 100 標本相関係数

`cor(x,y)`で算出 (R標準の`stats::cor`)

n = 1,000の場合と比べると若干の推定誤差が生じている




n = 100 分割相関

`gcor::gcor(x,y)` で算出。10対2ルールに基づいて $k = 2$ を自動設定

絶対値は標本相関係数と類似

非線形パターンを検出するには $k = 3$ などを手動で設定する必要がある




n = 100 距離相関

`energy::dcor(x,y)` で算出

独立なケースでも多少の推定誤差が生じているとみられる

小サンプルでも非線形関係を検出できている




n = 100 MIC

`minerva::mine(x,y)$MIC`で算出

小サンプルでも非線形関係を検出できている


独立なケースでも大きめの値を取りやすい



$n = 10,000$ 標本相関係数

`cor(x,y)`で算出 (R標準の`stats::cor`)

計算時間は平均0.0001秒程度




n = 10,000 分割相関

`gcor::gcor(x,y)` で算出。10対2ルールに基づいて $k = 8$ を自動設定

非線形なパターンを検出できているが、独立な場合でも0.1前後

計算時間は $n = 1,000$ のときの約4倍（平均0.003秒程度）




n = 10,000 距離相関

`energy::dcor(x,y)`で算出

n=1,000の場合より分割相関との差が開きがみられる

計算時間は大幅に増加し、n=1,000の**約134倍**（平均4.6秒程度）




n = 10,000 MIC

`minerva::mine(x,y)$MIC`で算出


n = 1,000の場合より分割相関との差が開きがみられる

計算時間は大幅に増加し、n = 1,000の**約60倍**（平均約1.9秒程度）




計算時間の比較

- 横軸がサンプルサイズ、縦軸が1回あたりの平均計算時間（秒）
- 分割相関（`gcor`）は計算時間の増加がゆるやか
- 距離相関（`dcor`）およびMIC（`mic`）は計算時間が急速に増加



計算時間の比較（両軸対数プロット）

- 距離相関（`dcor`）は小標本では高速だが、べき乗で増加
 - この実装ではメモリ消費も大幅増加し、 $n = 100,000$ では計算不能
- MIC（`mic`）もべき乗で増加するが、距離相関よりはゆるやか



手法比較のまとめ

- それぞれ評価基準が異なるため、目的に応じた手法選択が有効
- 距離相関は小標本でも高性能だが、大標本では計算量が大幅増
- MICは大標本では距離相関より高速だが、やはり計算量が増加しやすい
- 分割相関は大標本でも高速、離散データや欠損値にも対応

⇒ 大規模データの探索的解析には分割相関がおすすめ

性能は比較に用いたRパッケージおよび関数の実装などにも依存するため、本資料の作成時に試行した範囲での暫定的な評価です。

新しい相関指標：まとめ

分割相関（contingency correlation）

- 線形のみならず非線形な関係も評価
- データ型や分布を問わず、統一的に適用可能
 - 連続、離散、あるいはその混合
 - 外れ値や欠損を含む
 - 分布が非対称、裾が重い、多峰的
- 測定単位を問わない（単調変換に対して不変）
- 計算コストが低く、大規模データにも適用可能

⇒ **Rパッケージgcor**で容易に利用可能

■ 本日の資料とRパッケージ

<https://r-suzuki.github.io/ja>

分割相関の詳細は、上記URLで公開しているR研究集会2025
(2025/11/23 統計数理研究所) の資料に掲載

