

一般化相関尺度とその推定法

Generalized Correlation Measure and Its Estimation

鈴木 了太

suzuki@ef-prime.com

株式会社 ef-prime

2026年9月8日

2026年度 統計関連学会連合大会

本報告について

概要

相関関係の評価指標と推定手法を提案

- 数値やカテゴリ、欠損を含むデータに適用可能
- 古典的な相関係数の一般化にあたり、非線形な関係も評価
- 特定の分布を仮定せず、データの単調変換に対して不変

最近の進展

- 議論を整理し、指標や推定手法を改良
- RおよびPythonによる実装を公開、日時データにも対応

動機

数値やカテゴリ、欠損を含む多変量データ行列の分析
強い関係を持つ変数の組を探索したい

予測

目的変数 Y と関係の強い説明変数 X_i

知識発見

強い関係をもつ変数の組 (X_i, X_j)

方針

予測の観点に基づく評価 $R(X \rightarrow Y)$ を考える


- $[0, 1]$ に値をとる
- X と Y が独立のとき 0
- Y が X に完全従属するとき 1

完全従属 (complete dependence; Lancaster, 1963)

$P(Y = g(X)) = 1$ となる可測関数 g が存在するとき、
 Y が X に完全従属するという。 X から Y を決定論的に予測できる


着想：連続変数の離散化

連続変数の値域を分割し、離散変数として評価



$$f(x, y)$$

$$X \in \mathcal{X}, Y \in \mathcal{Y}$$



$$p(i, j) = P(X \in \mathcal{X}_i, Y \in \mathcal{Y}_j)$$

$$\mathcal{X} = \sqcup_{i=1}^k \mathcal{X}_i, \mathcal{Y} = \sqcup_{j=1}^k \mathcal{Y}_j$$

相互情報量（離散の場合）

- X と Y が独立のとき0
- Y が X に完全従属するとき Y の情報量 $H(Y)$

$$\begin{aligned} I(X; Y) &= \mathbb{E} \left[\log \frac{p(x, y)}{p_X(x)p_Y(y)} \right] \\ &= \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p_X(x)p_Y(y)} \end{aligned}$$

$$\begin{aligned} 0 \leq I(X; Y) &\leq H(Y) \\ &= - \sum_y p_Y(y) \log p_Y(y) \end{aligned}$$

不確実性係数 (Uncertainty Coefficient)

相互情報量を目的変数の情報量 $H(Y)$ で基準化

$$U(Y|X) = \frac{I(X; Y)}{H(Y)}$$

$$0 \leq U(Y|X) \leq 1$$

X によって説明できる、 Y の不確実性の割合


- X と Y が独立のとき0
- Y が X に完全従属するとき1

探索的データ解析ソフトウェア**Natto**において、変数間の関係进行评估する手法として利用 (Suzuki et al., 2006) <https://ef-prime.com/ja/product/>

離散化アプローチの利点

変数間の関係を2元分割表によって評価

- 数値やカテゴリ値のほか、欠損値も統一的に扱うことができる
(欠損値を特別なカテゴリ値として扱ってもよい)
- 行および列の順序を入れ替えても評価は変わらない
⇒ 非線形な関係を捉えることができる




上記の例は相互情報量や不確実性係数の意味で等価


連続分布の離散近似

- 変数ごとの分割数 k を増やせば真の分布のよい近似になる
- 推定時はサンプルサイズ n が大きいほど細かく分割できる


$k = 8$



$k = 16$



$k = 32$



相互情報量（連続の場合）

- 非線形な関係も評価することができる
- X と Y が独立のとき0
- 完全従属に近づくとき ∞ に発散

$$\begin{aligned} I(X; Y) &= \mathbb{E} \left[\log \frac{f(x, y)}{f_X(x) f_Y(y)} \right] \\ &= \iint f(x, y) \log \frac{f(x, y)}{f_X(x) f_Y(y)} dx dy \end{aligned}$$

以下、 I と略記する

相互情報量の離散近似

X, Y の値域をそれぞれ k 分割した確率変数 X_k, Y_k の相互情報量

$$\begin{aligned} I(X_k; Y_k) &= \mathbb{E} \left[\log \frac{p(i, j)}{p_X(i)p_Y(j)} \right] \\ &= \sum_{i=1}^k \sum_{j=1}^k p(i, j) \log \frac{p(i, j)}{p_X(i)p_Y(j)} \end{aligned}$$

これを I_k と書くと $I_k \leq I$

適当な正則条件のもとで、分割を細かくすれば $I_k \rightarrow I \ (k \rightarrow \infty)$

不確実性係数の漸近挙動

不確実性係数 $U(Y_k|X_k)$ について、 $k \rightarrow \infty$ の挙動を考える：

$$U(Y_k|X_k) = \frac{I(X_k; Y_k)}{H(Y_k)}$$

$$0 \leq U(Y_k|X_k) \leq 1$$

- 分子は真の相互情報量 $I(X; Y)$ に収束し、分母は ∞ に発散する
- $I(X; Y)$ が有限のとき、**不確実性係数は0に収束してしまう**

発想の転換

理論値としての評価指標を定め、その推定手法を考える

- 確率変数の型を問わない評価指標を定義
- 推定手法のひとつとして離散近似を検討
 - サンプルサイズ n に応じて分割数 k を大きくする想定
 - $k \rightarrow \infty$ の極限が意味のある値になるように設計

相互情報量（一般の場合）

$$I(X; Y) = \begin{cases} \mathbb{E} \left[\log \frac{dP_{X,Y}}{d(P_X \otimes P_Y)} \right] & (P_{X,Y} \ll P_X \otimes P_Y) \\ \infty & (\text{otherwise}) \end{cases}$$

dP/dQ はラドン=ニコディム微分

- $I \in [0, \infty]$
- $I = 0 \Leftrightarrow X$ と Y は独立
- 非線形な関係も評価することができる

提案：相互依存性の尺度

$$\psi(X; Y) := \begin{cases} \mathbb{E} \left[\frac{dP_{X,Y}}{d(P_X \otimes P_Y)} \right] & (P_{X,Y} \ll P_X \otimes P_Y) \\ \infty & (\text{otherwise}) \end{cases}$$

相互情報量から対数変換を除いたもの。以下、 ψ と略記

- $\psi \in [1, \infty]$
- $\psi = 1 \Leftrightarrow X$ と Y は独立
- 非線形な関係も評価することができる

相互情報量におけるKLダイバージェンスを
カイ二乗ダイバージェンスに置き換え、定数1を足したものに相当。
後述するさまざまな性質を示すことができる

依存性尺度の性質

- X, Y の支持集合の基数を k_X, k_Y とすると、 Y が X に完全従属するとき

$$\psi = k_Y \leq k_X$$

- (X, Y) が相関係数 ρ をもつ2変量正規分布に従うとき

$$\rho^2 = 1 - \psi^{-1}$$

⇒ これらの性質を利用して指標を定義する

基準化

$$R(X \rightarrow Y) := \begin{cases} \sqrt{\frac{1 - \psi^{-1}}{1 - k_Y^{-1}}} & k_Y > 1 \\ 0 & k_Y = 1 < k_X \end{cases}$$

- $[0, 1]$ に値をとる
- X と Y が独立のとき0、 Y が X に完全従属するとき1
- (X, Y) が2変量正規分布に従うとき、相関係数の絶対値 $|\rho|$ と一致

$k_X = k_Y = 1$ のときは「独立かつ完全従属」となるため、以降の議論から除外する

| 方針の再検討

- 目標とした性質を達成
 - $[0, 1]$ に値をとり、独立のとき0、完全従属のとき1
- 相関係数（の絶対値）を一般化したものとみなすことができる

これらの性質に加えて、対称性をもつ指標も定義できると望ましい

提案：一般化相関尺度

以下を満たす指標を一般化相関尺度 (Generalized Correlation Measures) と呼ぶことにする：

- $[0, 1]$ に値をとる
- X と Y が独立のとき0、互いに完全従属するとき1
- (X, Y) が2変量正規分布に従うとき、相関係数の絶対値 $|\rho|$ と一致

ここでは対称性を要求せず、定義を広くとる
先の $R(X \rightarrow Y)$ は上記を満たす

提案：カイ二乗情報相関

$$r_{\chi^2}(X, Y) := \begin{cases} \sqrt{\frac{1 - \psi^{-1}}{\sqrt{1 - k_X^{-1}} \sqrt{1 - k_Y^{-1}}}} & (k_X > 1) \wedge (k_Y > 1) \\ 0 & (k_X = 1 < k_Y) \vee (k_Y = 1 < k_X) \end{cases}$$

- $[0, 1]$ に値をとる
- X と Y が独立のとき0、互いに完全従属するとき1
- (X, Y) が2変量正規分布に従うとき、相関係数の絶対値 $|\rho|$ と一致

カイ二乗ダイバージェンスとの関係からカイ二乗情報相関と名付けた。
正式には「基準化カイ二乗情報相関」などと呼ぶべきかも知れない

カイ二乗情報相関の性質

一般化相関尺度の定義を満たすほか、次の性質をもつ：

対称性

$$r_{\chi^2}(X, Y) = r_{\chi^2}(Y, X)$$

変換不変性

可測同型な変換 u, v に対して $r_{\chi^2}(u(X), v(Y)) = r_{\chi^2}(X, Y)$

| 推定手法の検討

- ψ の値を推定できれば、カイ二乗情報相関を推定することができる
- 一般のデータ分布に適用するため、離散化アプローチを検討する

依存性尺度（連続の場合）

- X と Y が独立のとき1
- 完全従属に近づくとき ∞ に発散

$$\begin{aligned}\psi(X; Y) &= \mathbb{E} \left[\frac{f(x, y)}{f_X(x) f_Y(y)} \right] \\ &= \iint \frac{f(x, y)^2}{f_X(x) f_Y(y)} dx dy\end{aligned}$$

依存性尺度の離散近似

X, Y の値域をそれぞれ k 分割した確率変数 X_k, Y_k の依存性尺度

$$\begin{aligned}\psi(X_k; Y_k) &= \mathbb{E} \left[\frac{p(i, j)}{p_X(i)p_Y(j)} \right] \\ &= \sum_{i=1}^k \sum_{j=1}^k \frac{p(i, j)^2}{p_X(i)p_Y(j)}\end{aligned}$$

これを ψ_k と書くと、適当な正則条件のもとで
分割を細かくすれば $\psi_k \rightarrow \psi \ (k \rightarrow \infty)$

カイ二乗情報相関の離散近似

依存性尺度の収束に伴い、カイ二乗情報相関の離散近似も同様に収束

$$\begin{aligned} r_{\chi^2}(X_k, Y_k) &= \sqrt{\frac{1 - \psi_k^{-1}}{1 - k^{-1}}} \\ &\rightarrow \sqrt{1 - \psi^{-1}} = r_{\chi^2}(X, Y) \quad (k \rightarrow \infty) \end{aligned}$$

⇒ 離散化アプローチを応用した推定手法を検討

推定手法

分位点分割による推定

1. 分割数 k を定め、数値データを経験 k 分位点で分割
 2. 分割データについて依存性尺度 ψ を推定
 3. ψ の推定値を用いてカイ二乗情報相関を算出
-
- データを単調変換しても同じ結果が得られる（変換不変性）
 - 分割数 k はサンプルサイズ n に応じて決めることを検討

| 推定シミュレーション


以下を1,000回繰り返す：

- 平均0、分散1の2変量正規分布に相関係数 ρ を0.05刻みで設定
- サンプルサイズ n のデータを抽出
- 分割数 k を定め、 $r_{\chi^2}(X_k, Y_k)$ を推定

推定値の平均値、および90%区間をプロットして確認
 ρ の値ごとの平均絶対誤差（MAE）を平均した値も算出


$n = 100$ $k = 2$

赤の点線は真値。ばらつきは大きいが、真値の近くに分布




$n = 100$ $k = 4$

ばらつきが小さくなる一方、全体的にバイアスが大きくなり誤差が増加




$n = 100$ $k = 8$

さらにばらつきが小さく、バイアスが大きくなる



$n = 100$ $k = 16$


ばらつきがほとんどなくなり、真値からかけ離れた値に



$n = 1,000$ $k = 2$


サンプルサイズが大きいと2分割でも真値に近く、ばらつきも小さい

MAE: 0.054 (average)




$n = 1,000$ $k = 4$

一部バイアスが増加するが、全体的には誤差が減少



$n = 1,000$ $k = 8$


誤差が増加、バイアスの増加が目立つ



$n = 1,000$ $k = 16$

真値から大きく外れる


MAE: 0.148 (average)




$n = 10,000$ $k = 2$

バイアスが残るが、ばらつきはほとんどない


MAE: 0.046 (average)



$n = 10,000$ $k = 4$




$n = 10,000$ $k = 8$




$n = 10,000$ $k = 16$


16分割では誤差が増加する




$n = 100,000$ $k = 2$



$n = 100,000$ $k = 4$




$n = 100,000$ $k = 8$



$n = 100,000$ $k = 16$

この例では16分割でも全体的に良好



分割数の検討

サンプルサイズ n と分割数 k によって結果が変動
分割数 k の選択が課題

以下の観点から検討：

- 推定量の一致性（理論モデルによる考察）
- 有限標本での推定精度（数値シミュレーション）

⇒ 大標本で真値に収束し、小標本でも良好な選択基準を定める

分割数の自動選択


10対2基準

$$k = \max \left\{ 2, \left\lfloor \frac{1}{2} n^{\log_{10} 2} \right\rfloor \right\}$$


- $n \leq 100$ のとき2分割。 n が10倍になると k は2倍
- 数値シミュレーションで良好な結果
- 近似モデルに基づく理論上の検討とも整合
 - $k = o(\sqrt{n})$ のとき $n \rightarrow \infty$ のもとで一致性が得られる

n	k	n	k
100	2	1,000,000	32
1,000	4	10,000,000	64
10,000	8	100,000,000	128
100,000	16	1,000,000,000	256


n = 100 k = 2




$n = 1,000$ $k = 4$



$n = 10,000$ $k = 8$



$n = 100,000$ $k = 16$



適用例：数値データ


- ランダム生成した2次元の数値データを評価
- サンプルサイズ n 、分割数 k を動かして挙動を確認
 - 分割表のセルあたり平均サンプルサイズ n/k^2 にも注目
- 標本相関係数と比較

Wikipedia 「[ピアソンの積率相関係数](#)」掲載の例をもとに作成

- 出典：https://commons.wikimedia.org/wiki/File:Correlation_examples2.svg
 - CC0 1.0 Universal (パブリックドメイン)

| n = 1,000 標本相関係数


上段は相関係数 ρ の絶対値を1, 0.8, 0.4, 0に設定した2変量正規分布
小数点以下は1桁に丸めて表示（以降も同様）



| n = 1,000 カイ二乗情報相関 (k = 4)

10対2基準に基づいて k を設定 ($n/k^2 = 62.5$)


非線形なパターンを検出しつつ、正規分布に対しては $|\rho|$ に近い値



n = 100 標本相関係数

サンプルサイズが小さい場合


正規乱数に対しても多少の推定誤差が生じる



| n = 100 カイ二乗情報相関 (k = 2)


10対2基準に基づいて k を設定 ($n/k^2 = 25$)

正規分布に対しては $|\rho|$ に近いが、非線形パターンを検出できていない




n = 100 カイ二乗情報相関 (k = 3)

k を手動で設定。セルあたりのサンプルサイズは $n/k^2 \approx 11$ と小さい
近似バイアスが増加するものの、非線形パターンの検出には成功



$n = 10,000$ 標本相関係数


サンプルサイズが大きい場合について、小数点以下第2位まで表示
サンプルサイズを増やしても、非線形パターンについては0に近い



| $n = 10,000$ カイ二乗情報相関 ($k = 8$)

10対2基準に基づいて k を設定 ($n/k^2 \approx 156$)


非線形パターンの検出は良好、近似バイアスも抑えられている



| n = 10,000 カイ二乗情報相関 (k = 10)

10対2基準を参考に、集計結果が解釈しやすい k を設定 ($n/k^2 = 100$)

近似バイアスが若干増加するが、全体の傾向は大きく変わらない



適用例：型混合データ

数値とカテゴリが混在する例として、`iris`データに適用

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5.1	3.5	1.4	0.2	setosa
4.9	3	1.4	0.2	setosa
⋮				
7	3.2	4.7	1.4	versicolor
6.4	3.2	4.5	1.5	versicolor
⋮				
6.3	3.3	6	2.5	virginica
5.8	2.7	5.1	1.9	virginica

推定結果



10対2基準を適用してカイ二乗情報相関を推定 ($k = 2$)

`Species`との相関が最も強いのは`Petal.Width`、最も弱いのは`Sepal.Width`

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Sepal.Length	1.000	0.235	0.885	0.874	0.772
Sepal.Width	0.235	1.000	0.314	0.267	0.659
Petal.Length	0.885	0.314	1.000	0.950	0.832
Petal.Width	0.874	0.267	0.950	1.000	0.834
Species	0.772	0.659	0.832	0.834	1.000

推定結果の確認

相関の高い変数のほうが、*Species*ごとの分布がきれいに分かれる



評価

適用例の評価

- 型混合データに対して有効に働く
- 連続データにおいては非線形な相関関係も評価することができ、正規分布に従う場合は相関係数の絶対値に近い値をとる

考察

- 10対2基準はサンプルサイズの増加に対して計算量の増加が緩やか
- サンプルサイズが大きいほど近似精度も向上する設計であり、大規模データに適した手法といえる

| ソフトウェア実装

gcor

R/Pythonで利用可能。開発版はGitHubで公開（オープンソース）

<https://r-suzuki.github.io/gcor/>

- カイ二乗情報相関および関連指標を算出
- 数値、カテゴリ、**日時データ**に対応
- 欠損値や外れ値を含むデータにも有効



R版 gcor

CRANまたはGitHubからインストール可能

インストール

```
install.packages("gcor")
```

使用例

```
library(gcor)
```

```
gcor(iris)
```

```
#>           Sepal.Length Sepal.Width Petal.Length Petal.Width  Species
#> Sepal.Length      1.0000000    0.2349075    0.8846517    0.8741873 0.7718469
#> Sepal.Width       0.2349075    1.0000000    0.3143301    0.2669031 0.6591442
#> Petal.Length      0.8846517    0.3143301    1.0000000    0.9503289 0.8323583
#> Petal.Width       0.8741873    0.2669031    0.9503289    1.0000000 0.8339534
#> Species           0.7718469    0.6591442    0.8323583    0.8339534 1.0000000
```

Python版 gcor

PyPIまたはGitHubからインストール可能

インストール

```
pip install gcor
```

使用例

```
>>> from gcor import gcor
>>> import pandas as pd
>>> df = pd.DataFrame({
...     'x': x,
...     'y': y,
...     'z': ['a', 'a', 'b', 'b', 'c', 'c', 'd', 'd', 'e', 'e'],
... })
>>> gcor(df)
```

	x	y	z
x	1.000000	0.534522	0.838289
y	0.534522	1.000000	0.763233
z	0.838289	0.763233	1.000000

今後の課題

論文化に向けた整理・検討

- 先行研究を踏まえて議論を整理 (※)
- 理論的性質の考察

発展的な話題

- 手法やソフトウェアの改良
- データ可視化などの応用

※ 古くはK. Pearson (1904)に遡り、Linfoot (1957)の情報相関係数、Rényi (1959)による従属性指標の整理、Lancaster (1963)による完全従属の概念、Csiszár (1967)のカイ二乗ダイバージェンスなど。非線形相関の既存手法としてはSzékely et al. (2007)の距離相関、Reshef et al. (2011)のMIC、Chatterjee (2021)の順位相関など

参考：既存手法との比較を含む公開記事

https://r-suzuki.github.io/ja/20251212_rlang_advent_calendar/r_new_cor.html

| まとめ

相関関係の評価指標と推定手法を提案

指標の特徴

- 数値やカテゴリ、欠損を含むデータに適用可能
- 古典的な相関係数の一般化にあたり、非線形な関係も評価
- 特定の分布を仮定せず、データの単調変換に対して不変

実装

- RおよびPythonによるオープンソース実装を公開

| 本日の資料と公開ソフトウェア

<https://r-suzuki.github.io/ja>

